

Propuesta preliminar de un gemelo digital híbrido para molienda SAG centrado en SLGNN

Análisis arquitectónico, fundamento bibliográfico, problemas de investigación y programa de desarrollo

Documento de trabajo para discusión interna del equipo

Este informe fija únicamente el esqueleto fundamental de la propuesta. Las elecciones de implementación, los modelos específicos y el alcance de cada extensión permanecen deliberadamente abiertos hasta contar con evidencia experimental suficiente.

Equipo de trabajo del proyecto SLGNN

Versión preliminar para revisión y toma de decisiones

Índice

1. Propósito, contexto y estatus de la propuesta	1
2. La idea general y su reformulación técnica	1
2.1. De un surrogate de dinámica a un surrogate del proceso	1
2.2. Por qué una arquitectura jerárquica	2
3. Esqueleto fundamental de la propuesta	3
3.1. Compromiso 1: arquitectura modular, híbrida y multiescala	3
3.2. Compromiso 2: SLGNN como núcleo microdinámico	3
3.3. Compromiso 3: interfaz micro-macro explícita	3
3.4. Compromiso 4: modelo macroscópico de conminución y transporte	4
3.5. Compromiso 5: estimación de estados y actualización	4
3.6. Compromiso 6: decisión bajo restricciones	5
3.7. Compromiso 7: incertidumbre, OOD y despliegue gradual	5
3.8. Diagrama del esqueleto fundamental	6
4. Arquitectura propuesta y justificación bibliográfica	6
4.1. Capa de datos multifidelidad	6
4.2. Núcleo SLGNN multitarea	7
4.3. Coarse-graining como interfaz científica	7
4.4. Modelo macroscópico: primera recomendación	8
4.5. Estimación y gemelo operacional	8
4.6. Control predictivo y papel opcional del RL	8
4.7. Matriz de trazabilidad de decisiones	9
5. Qué queda fijado y qué queda a elección futura	10
5.1. Decisiones fijadas por el esqueleto	10
5.2. Decisiones deliberadamente abiertas	10
6. Problemas de investigación y análisis crítico	10
6.1. Escalabilidad y significado de una partícula aprendida	10
6.2. Rotura, nacimiento de fragmentos y cambio de topología	11
6.3. Pulpa, slurry pooling y multifísica	11
6.4. Sim-to-real y error de modelo	11
6.5. Rollout estable y fidelidad de magnitudes agregadas	12
6.6. Observabilidad y estimación	12
6.7. Control seguro, restricciones y recompensa	12

6.8. Desgaste y geometría variable	13
6.9. Gobernanza de datos y reproducibilidad	13
7. Programa de desarrollo recomendado	13
7.1. Fase 0: especificación y línea base	13
7.2. Fase 1: SLGNN como surrogate microdinámico validado	14
7.3. Fase 2: salidas globales y operador micro-macro	14
7.4. Fase 3: acoplamiento con conminución macroscópica	14
7.5. Fase 4: prototipo de control predictivo	15
7.6. Fase 5: estimación y datos de planta	15
7.7. Fase 6: RL supervisor opcional	15
7.8. Fase 7: desgaste, pulpa y circuito extendido	16
7.9. Roadmap visual	16
8. Primera formulación concreta y viable	16
8.1. Nombre provisional	16
8.2. Pregunta central de investigación	16
8.3. Hipótesis de trabajo	17
8.4. Alcance mínimo del prototipo	17
8.5. Inputs, estados, outputs y acciones	17
8.6. Objetivo de control	18
8.7. Qué no promete esta primera formulación	18
8.8. Criterios de éxito	18
9. Prioridades para la próxima decisión del equipo	18
10. Conclusiones	19
Bibliografía	20

1. Propósito, contexto y estatus de la propuesta

El equipo ha implementado la arquitectura SLGNN y reporta un desempeño favorable en sus pruebas internas. Dado que no se han incorporado a este informe métricas cuantitativas, configuraciones experimentales ni comparaciones completas con DEM, la afirmación anterior debe entenderse como un resultado preliminar comunicado por el equipo, no como una validación industrial independiente.

El siguiente paso conceptual consiste en utilizar SLGNN como núcleo de un sistema más amplio orientado a automatizar parte del flujo de modelamiento, análisis y decisión que acompaña al uso industrial de simulaciones DEM en molienda semiautógena. El documento de estado del arte aportado por el equipo constituye una cartografía inicial útil de temas - rotura, desgaste, acoplamientos multifísicos, control y gemelos digitales - pero mezcla grados de madurez diferentes y contiene afirmaciones que requieren validación fuente por fuente [1]. Por esta razón, el presente informe conserva su amplitud temática, pero fundamenta las decisiones arquitectónicas centrales en trabajos científicos e industriales identificables.

La propuesta general puede expresarse como

$$\begin{array}{l} \text{datos y simulaciones de alta fidelidad} \longrightarrow \text{núcleo microdinámico SLGNN} \\ \longrightarrow \text{modelo macroscópico de proceso} \longrightarrow \text{estimación y decisión restringida} \end{array} \quad (1)$$

No se propone, al menos en esta etapa, una red monolítica que sustituya simultáneamente toda la física, el circuito, los sensores y el controlador. Se propone un sistema **modular, híbrido, multiescala y jerárquico**. Esta decisión es el eje que organiza todo el informe.

Síntesis

La primera formulación concreta del proyecto será un **prototipo de gemelo digital híbrido de un molino SAG basado en SLGNN, un modelo macroscópico de conminución y un controlador predictivo restringido**. El prototipo inicial será evaluado en simulación. La asimilación de datos de planta, el aprendizaje por refuerzo, el desgaste avanzado y la multifísica completa se consideran extensiones posteriores, no requisitos simultáneos de la primera versión.

2. La idea general y su reformulación técnica

2.1. De un surrogate de dinámica a un surrogate del proceso

Una red de partículas como SLGNN puede aproximar la evolución de posiciones, velocidades, aceleraciones, energías o contactos. Eso no equivale todavía a modelar un proceso SAG completo. La operación industrial exige describir, con distintos niveles de resolución:

- la dinámica de bolas, rocas y contactos;
- la transferencia y disipación de energía;
- la rotura y la evolución de la distribución granulométrica;
- el transporte, la descarga, el hold-up y la recirculación;
- las variables globales de operación, como potencia, torque y carga;
- los estados internos no observables directamente;
- las decisiones de control bajo límites operacionales;

- fenómenos lentos como desgaste y cambio geométrico.

La literatura de simuladores gráficos demuestra que una dinámica de partículas puede aprenderse mediante grafos y message passing [2, 3]. Li y Sakai incorporan fronteras arbitrarias mediante una SDF y presentan la SGN como una vía hacia simulación acelerada y gemelos digitales de procesos de polvos [4]. Garrido Núñez, Schott y Padding trasladan esa idea a una molienda de alta energía con frontera móvil y añaden una salida global de energía disipada, mostrando que un mismo núcleo puede sostener simultáneamente un rollout local y una magnitud global relevante [6]. Estos trabajos justifican colocar SLGNN en la capa microdinámica.

Sin embargo, los modelos mecanísticos de conminución muestran que la evolución de la PSD requiere modelos de rotura, selección, transporte y balances de masa. El modelo multiescala de Carvalho y Tavares conecta información mecánica procedente de DEM con un balance poblacional [8]; el enfoque híbrido DEM-FRM-PBM de Zou, Zheng y Yang actualiza los espectros de energía a medida que cambia la PSD y evidencia que una distribución energética estática puede inducir deriva a tiempos largos [9]. De forma alternativa, el modelo heterárquico de Bisht y colaboradores aborda trituración, segregación y mezcla sin depender explícitamente del número total de partículas [10]. Estas referencias justifican que la dinámica granular y la conminución macroscópica sean módulos conectados, no una única cabeza indistinta.

2.2. Por qué una arquitectura jerárquica

Los distintos fenómenos operan en escalas diferentes. Las colisiones exigen una resolución temporal mucho más fina que el control de alimentación o agua; la evolución del liner es todavía más lenta. La arquitectura jerárquica reconoce esta separación:

microdinámica $\prec$ dinámica del proceso $\prec$ supervisión y optimización $\prec$ gestión de activos. (2)

La separación también aparece en control de circuitos de molienda. Le Roux y colaboradores proponen control no lineal del circuito con estimación de estados, distinguiendo dinámicas rápidas y lentas y evitando asumir realimentación completa [14]. Los desarrollos industriales de MPC para SAG se basan en modelos de respuesta del proceso, variables medibles y restricciones, no en un solver granular completo dentro del lazo regulatorio [16]. La literatura de RL aplicada a SAG concluye que una política aprendida puede contribuir como capa supervisora de setpoints, mientras MPC mantiene estabilidad y restricciones [18]. Por tanto, el controlador no se formula como una simple cabeza de SLGNN.

Límite o cautela

No debe confundirse *estar inspirado por un gemelo digital industrial* con *poseer ya un gemelo digital industrial*. Un sistema merece esa denominación operacional cuando mantiene una conexión sistemática con el activo o proceso real, actualiza estados o parámetros con observaciones y sostiene funciones de diagnóstico, pronóstico o decisión. La primera versión propuesta será un prototipo de gemelo híbrido en entorno simulado; la conexión con planta constituye una fase posterior.

3. Esqueleto fundamental de la propuesta

El esqueleto fundamental es el conjunto mínimo de decisiones que define la identidad del proyecto y que no debería alterarse sin reformular su objetivo. Se compone de siete compromisos.

3.1. Compromiso 1: arquitectura modular, híbrida y multiescala

Compromiso estructural

El sistema se descompone en módulos con interfaces físicas explícitas. Se combinarán componentes aprendidos y mecánicos. Ningún módulo debe recibir como entrada toda la información microscópica si su tarea puede resolverse mediante variables agregadas suficientes.

La modularidad facilita validación, reemplazo de componentes, trazabilidad de errores y desarrollo incremental. La hibridación permite imponer balances y restricciones donde existe conocimiento confiable, dejando a las redes la aproximación de operadores costosos o desconocidos.

3.2. Compromiso 2: SLGNN como núcleo microdinámico

Sea

$$X_t = \{(q_i^t, v_i^t, m_i, r_i, \tau_i, \dots)\}_{i=1}^{N_t}$$

el microestado granular, sea G_t la geometría del molino y sea u_t el conjunto de condiciones operacionales. El núcleo se expresa de manera abstracta como

$$(\hat{X}_{t+\Delta t}, H_t) = \mathcal{S}_\theta^{\text{SLGNN}}(X_t, G_t, u_t, \xi_t), \quad (3)$$

donde ξ_t representa propiedades materiales y H_t un estado latente útil para salidas auxiliares.

Este compromiso se apoya en GNS [2], en la SGN con SDF [4], en el surrogate de molienda de Garrido Núñez [6] y en la descomposición energética y disipativa que inspira la arquitectura SLGNN [5].

3.3. Compromiso 3: interfaz micro-macro explícita

El controlador y el modelo poblacional no deben operar directamente sobre millones de coordenadas. Se introduce un operador de coarse-graining

$$C_t = \mathcal{C}_\phi(X_t, H_t), \quad (4)$$

con salidas posibles

$$C_t = [P_t, \tau_t, J_t, \text{CoM}_t, \mathcal{E}_t^{\text{coll}}, \Lambda_t^{\text{wall}}, \Phi_t^{\text{discharge}}, \dots]. \quad (5)$$

Aquí $\mathcal{E}_t^{\text{coll}}$ denota un espectro o distribución de energías de colisión, Λ_t^{wall} un campo agregado de carga sobre la pared y $\Phi_t^{\text{discharge}}$ una medida de flujo de descarga. La elección exacta se determinará por utilidad predictiva y costo.

Compromiso estructural

Debe existir una interfaz micro-macro interpretable y verificable. Su función es traducir la dinámica de partículas en variables que alimenten rotura, transporte, estimación y control.

El precedente bibliográfico más directo es la cabeza global de energía de Garrido Núñez et al. [6]. Los modelos DEM-PBM muestran además que los espectros de colisión pueden parametrizar la evolución de rotura [8, 9].

3.4. Compromiso 4: modelo macroscópico de conminución y transporte

Sea z_k un estado macroscópico en una escala temporal más gruesa:

$$z_k = [M_{1,k}, \dots, M_{B,k}, W_k, J_{b,k}, J_{c,k}, \theta_k^{\text{ore}}, L_k]. \quad (6)$$

Las variables $M_{b,k}$ pueden representar masas por clase de tamaño, W_k agua o pulpa, J_b carga de bolas, J_c carga total, θ^{ore} propiedades efectivas del mineral y L_k estado del revestimiento. La evolución abstracta es

$$z_{k+1} = \mathcal{F}_\psi(z_k, u_k, C_k, d_k), \quad (7)$$

donde d_k representa perturbaciones o propiedades de alimentación.

Decisión abierta

La forma específica de $\mathcal{F}_\psi$ queda abierta. Las opciones principales son: un PBM informado por energía; un modelo mecanístico reducido con balances; una Neural ODE híbrida; o un modelo heterárquico. La primera recomendación es comenzar con un PBM o balance poblacional híbrido por su interpretabilidad, madurez y conexión directa con la PSD.

3.5. Compromiso 5: estimación de estados y actualización

En una planta, la mayoría de los estados de z_k no son medibles de forma directa. Se requiere una capa de observación

$$y_k = \mathcal{H}(z_k, u_k) + \varepsilon_k \quad (8)$$

y un estimador

$$\hat{z}_k = \mathcal{O}_\omega(y_{0:k}, u_{0:k-1}). \quad (9)$$

La literatura de SAG incluye modelos dinámicos con estimación online [12], observadores EKF para hold-ups de agua, sólidos y medios de molienda [15], filtros de partículas integrados con control no lineal [14] y gemelos basados en redes recurrentes con detección de perturbaciones y criterio de reentrenamiento [17].

Compromiso estructural

La estimación de estados es parte del esqueleto de un gemelo operacional. No obstante, puede omitirse en el primer prototipo puramente simulado, donde el estado verdadero está disponible. Debe incorporarse antes de cualquier validación con datos de planta.

3.6. Compromiso 6: decisión bajo restricciones

El controlador base será de tipo predictivo. De forma abstracta,

$$\min_{u_{k:k+H-1}} \sum_{h=0}^{H-1} \ell(\hat{z}_{k+h}, u_{k+h}) + V_f(\hat{z}_{k+H}) \quad (10)$$

$$\text{sujeto a } \hat{z}_{k+h+1} = \mathcal{F}_\psi(\hat{z}_{k+h}, u_{k+h}, C_{k+h}), \quad (11)$$

$$u_{\min} \leq u_{k+h} \leq u_{\max}, \quad (12)$$

$$g(\hat{z}_{k+h}, u_{k+h}) \leq 0. \quad (13)$$

Una función económica ilustrativa es

$$\ell = -\lambda_Q Q + \lambda_E \frac{P}{Q} + \lambda_{80} (P_{80} - P_{80}^*)^2 + \lambda_W \dot{W}_{\text{liner}}. \quad (14)$$

La experiencia industrial reporta uso de MPC para reducir variabilidad y controlar peso de molino frente a retardos e interacción multivariable [16]. La literatura académica de circuitos de molienda incorpora observadores, restricciones y objetivos de throughput y calidad [14].

Decisión abierta

Se recomienda MPC económico como controlador de referencia, pero queda abierta la elección entre MPC lineal adaptativo, NMPC, MPC híbrido o una versión basada en un surrogate diferenciable. El criterio de elección será la relación entre fidelidad, costo online, tratamiento de incertidumbre y garantías.

3.7. Compromiso 7: incertidumbre, OOD y despliegue gradual

Garrido Núñez et al. observan sesgos bajo movimientos fuera de distribución y recomiendan cuantificación de incertidumbre y detección OOD [6]. Quintanilla et al. incorporan detección de perturbaciones para decidir cuándo actualizar el gemelo [17]. Estas evidencias motivan una capa transversal de confianza:

$$(\hat{y}, \hat{\sigma}, \gamma_{\text{OOD}}) = \mathcal{U}(X, z, u), \quad (15)$$

donde $\hat{\sigma}$ representa incertidumbre y γ_{OOD} un indicador de extrapolación.

Compromiso estructural

El sistema no debe entregar recomendaciones de control sin acompañarlas de diagnósticos de validez. El despliegue seguirá una progresión: simulación offline, shadow mode, recomendador, supervisión humana y, solo después, lazo cerrado limitado.

3.8. Diagrama del esqueleto fundamental




Figura 1: Esqueleto fundamental. Los bloques azules son compromisos estructurales; los bloques naranjos son extensiones cuya inclusión y forma permanecen abiertas.

4. Arquitectura propuesta y justificación bibliográfica

4.1. Capa de datos multifidelidad

La primera capa no es una red, sino un sistema de generación, curación y versionado de datos. Debe integrar, en la medida disponible:

$$\mathcal{D} = \mathcal{D}_{\text{DEM}} \cup \mathcal{D}_{\text{piloto}} \cup \mathcal{D}_{\text{planta}} \cup \mathcal{D}_{\text{multifísica}}. \quad (16)$$

DEM seguirá siendo el profesor de alta fidelidad para la dinámica granular. Los datos piloto y de planta son necesarios para controlar el sim-to-real gap. Los datos multifísicos, por ejemplo DEM-SPH, se reservarán para fenómenos donde la pulpa sea decisiva. Cleary y colaboradores muestran que el acoplamiento DEM-SPH puede describir movimiento, rotura de partículas gruesas y transporte de finos en un SAG, pero con un costo y una complejidad que desaconsejan imponerlo como requisito inicial [13].

Una política de active learning puede seleccionar nuevas simulaciones cuando el surrogate presente alta incertidumbre:

$$\theta_{\text{next}}^* = \arg \max_{\theta \in \Theta_{\text{cand}}} [\text{Unc}(\theta) + \beta \text{Value}(\theta)]. \quad (17)$$

4.2. Núcleo SLGNN multitarea

El núcleo no se limita a una aceleración. La recomendación es conservar un tronco compartido y varias salidas físicamente relacionadas:

$$\hat{a}_i = D_a(H_t)_i, \quad (18)$$

$$\hat{e}_{ij}^{\text{diss}} = D_E(H_t)_{ij}, \quad (19)$$

$$\hat{P}_t = D_P(H_t), \quad (20)$$

$$\hat{\tau}_t = D_\tau(H_t), \quad (21)$$

$$\hat{\mathcal{E}}_t^{\text{coll}} = D_{\text{spec}}(H_t), \quad (22)$$

$$\hat{\Lambda}_t^{\text{wall}} = D_{\text{wall}}(H_t). \quad (23)$$

La salida cinemática sostiene el rollout. Las salidas globales deben tener pérdidas supervisadas propias; el estudio de Garrido Núñez muestra que una cabeza global de disipación puede quedar severamente descalibrada si no recibe supervisión global explícita, incluso cuando la cinemática permanece estable [6]. Por ello, una pérdida total ilustrativa es

$$\mathcal{L} = \alpha_x \mathcal{L}_{\text{rollout}} + \alpha_E \mathcal{L}_{\text{energy}} + \alpha_P \mathcal{L}_{\text{power}} + \alpha_{\text{spec}} \mathcal{L}_{\text{spectrum}} + \mathcal{R}_{\text{physics}}. \quad (24)$$

Decisión abierta

No todas las cabezas deben implementarse a la vez. Para la primera versión se recomiendan: cinemática, potencia/torque o energía disipada, y espectro de colisiones. El campo de desgaste, las fuerzas detalladas y la rotación pueden incorporarse después si aportan a un objetivo verificable.

4.3. Coarse-graining como interfaz científica

El operador $\mathcal{C}_\phi$ no debe tratarse como un simple pooling arbitrario. Debe diseñarse a partir de magnitudes de proceso:

- integrales de masa y ocupación por región;
- centro de masa, toe y shoulder de la carga;
- histogramas diferenciables de energía, ángulo y tipo de contacto;
- potencia y torque por balance;
- flujo a través de regiones próximas a la parrilla;
- campos de carga sobre liners;
- descriptores por clase granulométrica o tipo de partícula.

El criterio de suficiencia será empírico: una representación $\mathcal{C}_t$ es útil si permite predecir las variables macroscópicas con menor error y mayor transferibilidad que una parametrización basada solo en setpoints.

4.4. Modelo macroscópico: primera recomendación

Para una PSD discretizada en B clases, un balance poblacional genérico puede escribirse como

$$\frac{dM_b}{dt} = \underbrace{\sum_{j>b} S_j B_{b \leftarrow j} M_j - S_b M_b}_{\text{rotura}} + \underbrace{F_b^{\text{in}} - F_b^{\text{out}}}_{\text{transporte y descarga}}, \quad (25)$$

donde las tasas S_b y las distribuciones de progenie $B_{b \leftarrow j}$ dependen de propiedades del mineral y del espectro energético aportado por SLGNN:

$$S_b = S_b(\mathcal{E}^{\text{coll}}, \theta^{\text{ore}}, z, u). \quad (26)$$

La razón para privilegiar esta formulación en la primera versión es pragmática:

1. conserva explícitamente masas por clase;
2. produce directamente una PSD y variables como P_{80} ;
3. acepta tasas de rotura informadas por energía;
4. conecta con una larga tradición de modelamiento y control de molinos [11, 12];
5. permite reemplazar submodelos sin reentrenar todo el sistema.

El trabajo de Zou et al. refuerza la necesidad de actualizar el espectro energético conforme se acumulan finos y cambia el régimen de colisiones [9]. El modelo heterárquico reciente ofrece una alternativa atractiva cuando la independencia respecto del número de partículas y la resolución espacial de la PSD sean prioritarias [10]. Esa comparación debe quedar para una etapa de selección de modelo.

4.5. Estimación y gemelo operacional

El prototipo simulado puede acceder a z_k . Una implementación real no. La estimación deberá integrar medidas disponibles, por ejemplo:

$$y_k = [P_k, \tau_k, W_k^{\text{mill}}, \text{sound}_k, F_k^{\text{feed}}, F_k^{\text{water}}, \text{PSD}_k^{\text{feed}}, \dots]. \quad (27)$$

El estado estimado podría distinguir agua, sólidos descargables, rocas gruesas y medios de molienda, siguiendo la lógica de observadores desarrollados para SAG [15]. La actualización del modelo ante perturbaciones no debe ser continua por defecto: el gemelo de Quintanilla et al. utiliza detección de desviaciones para decidir cuándo reentrenar [17]. Esto sugiere una arquitectura con tres operaciones separadas:

$$\text{filtrado de estado} \quad + \quad \text{detección de mismatch} \quad + \quad \text{actualización controlada de parámetros.} \quad (28)$$

4.6. Control predictivo y papel opcional del RL

La literatura industrial de MPC para SAG enfatiza retardos, respuesta integradora, sobrecarga y multivariableidad [16]. La literatura académica muestra que la estimación de estados es tan importante como el optimizador [14]. Por ello, la primera política de decisión debe ser un controlador explícitamente restringido.

El RL se mantiene como extensión porque puede explorar objetivos de circuito, secuencias largas y

políticas adaptativas. No obstante, el estudio de Reyes et al. registra sensibilidad a la recompensa, diferencias entre semillas, comportamientos oscilatorios y ausencia de garantías de estabilidad; su conclusión propone RL supervisor de setpoints y MPC regulatorio [18]. Los marcos de safe RL con MPC robusto ofrecen una justificación general para esta separación [19].

Una arquitectura futura sería

$$\pi_{\rho}^{\text{RL}}(\hat{z}_k) \longrightarrow (r_k, \lambda_k, \mathcal{M}_k), \quad \text{MPC}(r_k, \lambda_k, \mathcal{M}_k) \longrightarrow u_k, \quad (29)$$

donde r_k son setpoints, λ_k pesos económicos y $\mathcal{M}_k$ un modo operacional. El RL no enviaría acciones directas al variador o a la alimentación sin un filtro de factibilidad.

4.7. Matriz de trazabilidad de decisiones

Cuadro 1: Relación entre decisiones arquitectónicas, evidencia y consecuencia para la propuesta.

Decisión	Inspiración bibliográfica	Razón de inclusión
Núcleo de partículas basado en grafos	GNS [2]; surrogate granular [3]	Las interacciones locales y la invariancia a permutaciones se representan naturalmente mediante nodos, aristas y message passing.
Frontera mediante SDF	Li y Sakai [4]; Garrido Núñez et al. [6]	Permite geometrías arbitrarias y móviles sin poblar toda la pared con nodos virtuales.
Salidas globales junto al rollout	Garrido Núñez et al. [6]	La dinámica local puede alimentar magnitudes globales relevantes; cada cabeza requiere calibración y supervisión propias.
Sesgos energéticos y disipativos	LGNN [5] y formulación previa de SLGNN	Mejora interpretabilidad y coherencia física, especialmente en un sistema fuertemente disipativo.
Interfaz mediante espectros de colisión	Carvalho-Tavares [8]; DEM-FRM-PBM [9]	La distribución de energías conecta la mecánica de contactos con tasas de rotura y evita reducir toda la dinámica a una energía promedio.
Modelo macroscópico separado	PBM dinámicos [11, 12]; heterarquía [10]	La PSD, el transporte y el hold-up requieren estados y escalas diferentes de la trayectoria partícula a partícula.
Estimación de estados	Le Roux et al. [14, 15]; Quintanilla et al. [17]	Los estados internos no son observables directamente; el gemelo debe inferirlos y detectar mismatch.
MPC como controlador base	ANDRITZ [16]; NMPC de circuitos [14]	Trata retardos, restricciones, interacciones y objetivos económicos con una estructura verificable.
RL supervisor, no regulatorio	Reyes et al. [18]; safe RL-MPC [19]	Conserva capacidad adaptativa sin delegar estabilidad y restricciones a una política no certificada.
OOD e incertidumbre	Garrido Núñez et al. [6]; detección de perturbaciones [17]	Un surrogate puede fallar por cambio de material, geometría o régimen; el sistema debe detectar cuándo no confiar.

5. Qué queda fijado y qué queda a elección futura

5.1. Decisiones fijadas por el esqueleto

1. **El proyecto no será monolítico.** Existirán módulos diferenciados para microdinámica, coarse-graining, proceso, estimación y decisión.
2. **SLGNN será el núcleo granular.** Su función primaria será reemplazar o acelerar la parte recurrente y costosa de DEM que sea pertinente para el objetivo.
3. **La interfaz con conminución será explícita.** Se priorizarán magnitudes físicas, en particular espectros de energía/contacto y variables globales.
4. **La evolución granulométrica se modelará en una escala macroscópica.** No se exige representar cada fragmento como un nuevo nodo en la primera versión.
5. **El controlador será restringido.** La primera referencia será MPC o una variante predictiva equivalente.
6. **La incertidumbre y la validez del modelo formarán parte del sistema.**
7. **El desarrollo será incremental y con puertas de validación.**

5.2. Decisiones deliberadamente abiertas

- PBM clásico, modelo heterárquico, Neural ODE híbrida u otra formulación macro;
- número y definición de clases granulométricas;
- si la rotura se simula explícitamente en una subescala o solo mediante estadísticas;
- conjunto final de cabezas de SLGNN;
- representación de pulpa y momento de incorporar DEM-SPH o un modelo reológico reducido;
- forma del modelo de desgaste y actualización de geometría;
- estimador EKF, UKF, filtro de partículas, MHE o red recurrente;
- MPC lineal adaptativo, NMPC, economic MPC, robust MPC o stochastic MPC;
- uso de RL, algoritmo, recompensa y frecuencia de decisión;
- suite de sensores y variables manipuladas de una planta concreta;
- estrategia de coarse graining y escala física representada por cada nodo;
- plataforma DEM, dataset, geometría, mineral y condiciones de referencia.

Límite o cautela

Mantener estas decisiones abiertas no es falta de precisión. Es una decisión metodológica: fijar ahora detalles no respaldados por datos crearía una falsa sensación de madurez y podría encerrar el proyecto en una implementación incorrecta. Cada elección futura debe estar asociada a un experimento discriminante y a un criterio de aceptación.

6. Problemas de investigación y análisis crítico

6.1. Escalabilidad y significado de una partícula aprendida

Li y Sakai observan que los procesos industriales pueden contener órdenes de magnitud más partículas que una simulación convencional [4]. El modelo heterárquico de SAG cuantifica una

brecha de hasta ocho órdenes de magnitud entre la cantidad física y la manejable por DEM [10]. Por tanto, ni DEM ni SLGNN deben interpretarse automáticamente como una representación literal de cada grano industrial.

El problema científico es definir qué representa un nodo:

$$\text{grano físico} \quad \text{o} \quad \text{superpartícula} \quad \text{o} \quad \text{paquete de masa} \quad \text{o} \quad \text{elemento mesoscópico}. \quad (30)$$

La elección debe preservar, al menos aproximadamente, masa, impulso, energía de contacto y estadísticas de colisión relevantes. La evaluación debe incluir generalización al número de nodos y al escalamiento geométrico, no solo error en una configuración fija.

6.2. Rotura, nacimiento de fragmentos y cambio de topología

La rotura explícita induce un grafo de tamaño variable:

$$N_{t+1} = N_t - 1 + n_{\text{frag}}, \quad E_{t+1} \neq E_t. \quad (31)$$

Aprender nacimiento y desaparición de nodos es posible, pero aumenta significativamente la dificultad de estabilidad, conservación y entrenamiento. Para la primera versión se recomienda evitar esta complejidad mediante la separación:

$$\text{SLGNN predice condiciones de solicitud} \quad \longrightarrow \quad \text{PBM predice evolución de tamaños}. \quad (32)$$

El experimento crítico será comparar un PBM informado por el espectro aprendido contra uno informado por datos DEM y contra uno con tasas fijas.

6.3. Pulpa, slurry pooling y multifísica

La molienda SAG industrial es húmeda. Un modelo solo granular puede ser adecuado para estudiar ciertos regímenes de carga, pero no garantiza predicción de transporte de finos, amortiguamiento hidrodinámico o descarga. DEM-SPH ofrece una vía de alta fidelidad [13]; no obstante, su costo lo vuelve más apropiado como generador de datos selectivo que como componente obligatorio online.

Una estrategia escalonada es:

1. comenzar con seco o con efectos de pulpa parametrizados;
2. añadir variables globales de sólidos y agua al modelo macro;
3. generar un subconjunto DEM-SPH para calibrar un surrogate reológico;
4. incorporar campos fluidos solo si la métrica de interés lo exige.

6.4. Sim-to-real y error de modelo

Si SLGNN aprende de DEM, entonces aproxima la distribución del solver:

$$p_{\text{SLGNN}} \approx p_{\text{DEM}}, \quad (33)$$

no necesariamente la distribución de planta. El error total puede descomponerse como

$$\underbrace{e_{\text{plant}}}_{\text{error respecto de la realidad}} \leq \underbrace{e_{\text{DEM}}}_{\text{calibración y física omitida}} + \underbrace{e_{\text{sur}}}_{\text{aproximación de SLGNN}} + \underbrace{e_{\text{roll}}}_{\text{acumulación temporal}} + \underbrace{e_{\text{OOD}}}_{\text{cambio de régimen}}. \quad (34)$$

Por eso la validación debe ser jerárquica: primero contra DEM, luego contra experimento piloto y finalmente contra datos de planta. Salazar et al. muestran la relevancia de estimación online y validación en un molino industrial [12]; Quintanilla et al. incorporan detección de perturbaciones para evitar asumir estacionariedad indefinida [17].

6.5. Rollout estable y fidelidad de magnitudes agregadas

Un bajo error de aceleración a un paso no garantiza un rollout útil. Tampoco un rollout visualmente plausible garantiza que potencia, energía o colisiones estén calibradas. La evaluación debe separar:

error local de transición, (35)

error de trayectoria, (36)

error de invariantes o balances, (37)

error de estadísticos de contacto, (38)

error de variables de proceso. (39)

El precedente de Garrido Núñez muestra que la cabeza global necesita una pérdida propia y que el error OOD puede manifestarse más en energía que en cinemática [6].

6.6. Observabilidad y estimación

Un gemelo no puede depender de estados que la planta no puede medir o inferir. El problema de observabilidad debe plantearse antes de diseñar el controlador. Los trabajos de Le Roux et al. muestran que los hold-ups pueden estimarse mediante observadores y mediciones disponibles, pero la calidad depende del modelo y de la identificabilidad [14, 15].

Preguntas centrales:

- ¿qué estados son identificables con potencia, peso, sonido, flujos y granulometría de alimentación?;
- ¿qué parámetros de mineral pueden actualizarse sin confundirlos con desgaste o error de sensor?;
- ¿qué sensores adicionales aportan información no redundante?;
- ¿cómo se cuantifica la incertidumbre del estado estimado?;

6.7. Control seguro, restricciones y recompensa

El RL para SAG ha mostrado que una recompensa mal diseñada puede producir soluciones triviales o inestables, y que distintas semillas pueden entregar políticas cualitativamente diferentes [18]. El controlador debe respetar límites de potencia, carga, velocidad, tasa de cambio, agua y riesgo de

sobrecarga. Por ello:

$$\text{optimización de desempeño} \quad \text{no sustituye} \quad \text{certificación de factibilidad.} \quad (40)$$

El enfoque recomendado es usar MPC como baseline y, si se incorpora RL, restringirlo mediante una capa predictiva o un filtro de seguridad, siguiendo la lógica de robust MPC safe RL [19].

6.8. Desgaste y geometría variable

El desgaste afecta la SDF, las trayectorias y la eficiencia de transferencia de energía. Sin embargo, evoluciona en una escala mucho más lenta que el control. Por ello se recomienda tratarlo como estado de activo L_k actualizado en ventanas largas:

$$L_{k+1} = L_k + \Delta t_{\text{wear}} \mathcal{W}(\Lambda_k^{\text{wall}}, L_k, \theta^{\text{liner}}). \quad (41)$$

La geometría actualizada alimentaría nuevamente la SDF. El modelo de desgaste exacto queda abierto; su inclusión temprana solo se justifica si existe un dataset de perfiles de liner o una pregunta de mantenimiento concreta.

6.9. Gobernanza de datos y reproducibilidad

El sistema contendrá datos simulados y eventualmente industriales. Deben versionarse:

- solver y parámetros DEM;
- geometría y versión del liner;
- propiedades del mineral;
- condiciones operacionales;
- normalizaciones y criterios de contacto;
- particiones de entrenamiento, validación y OOD;
- código, pesos y métricas.

Sin esa trazabilidad, un buen resultado puede ser imposible de reproducir o atribuir a una decisión física particular.

7. Programa de desarrollo recomendado

El programa debe avanzar mediante puertas de validación. Cada fase agrega una capacidad, pero no se inicia la siguiente si la anterior no entrega evidencia suficiente.

7.1. Fase 0: especificación y línea base

Objetivo. Definir el caso de referencia, variables, geometría, materiales y métricas.

Entregables.

- dataset DEM versionado;
- baseline DEM y baseline GNS/SGN o modelo directo;
- conjunto de escenarios IID y OOD;

- protocolo de evaluación de rollout y variables globales;
- inventario de supuestos físicos.

Puerta G0. El equipo puede reproducir el dataset y las métricas desde cero.

7.2. Fase 1: SLGNN como surrogate microdinámico validado

Objetivo. Verificar estabilidad, precisión y generalización de la dinámica.

Métricas mínimas.

- error de aceleración y posición;
- estabilidad de rollout en horizontes crecientes;
- conservación o disipación consistente;
- penetración de pared y fallos topológicos;
- generalización a condiciones, geometrías y cantidades de partículas no vistas;
- factor de aceleración computacional.

Puerta G1. El surrogate reproduce las observables definidas con error aceptable y sin inestabilidad sistemática.

7.3. Fase 2: salidas globales y operador micro-macro

Objetivo. Predecir variables de proceso derivadas de la dinámica.

Prioridad recomendada.

$$\text{potencia/torque} \rightarrow \text{energía disipada} \rightarrow \text{espectro de colisiones} \rightarrow \text{carga de pared.} \quad (42)$$

Ablaciones.

- heads independientes frente a head compartida;
- pooling simple frente a histogramas físicos;
- supervisión local frente a local+global;
- inputs con y sin propiedades materiales.

Puerta G2. Las variables agregadas se mantienen calibradas en rollout y aportan información adicional frente a usar solo setpoints.

7.4. Fase 3: acoplamiento con conminución macroscópica

Objetivo. Predecir evolución de PSD, hold-up y descarga en una escala de proceso.

Experimento central. Comparar tres modelos:

1. PBM con parámetros fijos;
2. PBM informado por espectros DEM;
3. PBM informado por espectros SLGNN.

Criterio. La tercera opción debe aproximar a la segunda con costo menor y superar a la primera en escenarios cambiantes.

Puerta G3. El sistema híbrido predice PSD y balances con precisión suficiente durante horizontes mayores que el rollout granular original.

7.5. Fase 4: prototipo de control predictivo

Objetivo. Optimizar en simulación throughput, energía específica y calidad bajo restricciones.

Acciones candidatas.

$$u_k = [F_k^{\text{feed}}, F_k^{\text{water}}, \omega_k, u_k^{\text{crusher}}]. \quad (43)$$

Comparaciones.

- política fija o reglas;
- PID/expert-like simplificado;
- MPC con modelo macro;
- MPC con actualización de SLGNN;
- optimización robusta frente a nominal.

Puerta G4. El controlador mejora el costo acumulado sin violar restricciones en escenarios de perturbación definidos.

7.6. Fase 5: estimación y datos de planta

Objetivo. Sustituir estados verdaderos por estados inferidos desde observaciones.

Secuencia.

1. generar sensores sintéticos y ruido;
2. evaluar observabilidad;
3. comparar EKF/UKF, filtro de partículas, MHE y redes recurrentes;
4. detectar mismatch y OOD;
5. incorporar datos piloto o industriales cuando existan.

Puerta G5. La degradación de control causada por estimación es cuantificada y aceptable; el sistema sabe cuándo declarar baja confianza.

7.7. Fase 6: RL supervisor opcional

Objetivo. Aprender setpoints, modos o pesos económicos sobre el gemelo, sin reemplazar la capa de seguridad.

Requisitos previos.

- entorno validado;
- restricciones codificadas;
- baseline MPC competitivo;
- pruebas multisesmilla;
- evaluación OOD y de robustez;
- safety filter o MPC de respaldo.

Puerta G6. El RL aporta mejora estadísticamente robusta sobre MPC y no aumenta violaciones tras el filtro de seguridad.

7.8. Fase 7: desgaste, pulpa y circuito extendido

Esta fase agrupa extensiones de alto costo que deben priorizarse por valor industrial:

- desgaste y actualización de SDF;
- surrogate de pulpa calibrado con DEM-SPH;
- parrilla, pebbles y circuito cerrado;
- interacción con molienda secundaria y clasificación;
- optimización de mantenimiento y diseño.

7.9. Roadmap visual




Figura 2: Programa incremental. Las fases naranjas son extensiones opcionales sujetas a valor y evidencia.

8. Primera formulación concreta y viable

8.1. Nombre provisional

Gemelo digital híbrido de un molino SAG basado en SLGNN, balance poblacional informado por energía y control predictivo

8.2. Pregunta central de investigación

Síntesis

¿Puede una arquitectura SLGNN aprender la microdinámica granular y producir estadísticas energéticas suficientemente informativas para alimentar un modelo macroscópico de conminución y permitir optimización predictiva restringida a un costo muy inferior al de campañas repetidas de DEM?

8.3. Hipótesis de trabajo

1. **H1 - Microdinámica:** SLGNN reproduce rollouts y observables globales de DEM en el dominio de entrenamiento y en un conjunto OOD delimitado.
2. **H2 - Interfaz:** un espectro de colisiones aprendido contiene información suficiente para actualizar tasas de rotura mejor que usar parámetros fijos.
3. **H3 - Multiescala:** el acoplamiento SLGNN-PBM predice evolución de PSD durante horizontes mayores que el surrogate puramente granular.
4. **H4 - Optimización:** un MPC basado en el modelo híbrido mejora un objetivo económico simulado sin violar restricciones.
5. **H5 - Confianza:** una medida de incertidumbre u OOD identifica escenarios en los que el modelo no debe utilizarse para decisión.

8.4. Alcance mínimo del prototipo

El prototipo mínimo debe contener cuatro componentes:

1. **SLGNN dinámico multitarea**, con salida cinemática y al menos una salida energética global;
2. **operador micro-macro**, con espectro de energías de colisión y variables globales;
3. **modelo macroscópico**, inicialmente un PBM informado por energía y balances de masa;
4. **control predictivo en simulación**, con una función económica y restricciones explícitas.

La estimación de estados se simulará mediante acceso al estado verdadero o ruido controlado en la primera versión. Se incorporará como módulo real en una fase posterior.

8.5. Inputs, estados, outputs y acciones

Entradas microdinámicas candidatas:

$$[X_t, G_t, \omega_t, \theta^{\text{ore}}, \theta^{\text{ball}}, J_b, J_c]. \quad (44)$$

Salidas de SLGNN candidatas:

$$[\hat{X}_{t+\Delta t}, \hat{P}_t, \hat{\tau}_t, \hat{E}_t^{\text{diss}}, \hat{\mathcal{E}}_t^{\text{coll}}]. \quad (45)$$

Estado macroscópico mínimo:

$$z_k = [M_{1,k}, \dots, M_{B,k}, J_{c,k}, W_k]. \quad (46)$$

Outputs del proceso:

$$[P_k, \tau_k, Q_k, P_{80,k}, J_{c,k}, \Phi_k^{\text{pebble}}]. \quad (47)$$

Acciones candidatas:

$$u_k = [F_k^{\text{feed}}, F_k^{\text{water}}, \omega_k, u_k^{\text{crusher}}]. \quad (48)$$

No es necesario que todas las acciones estén disponibles en el primer caso de estudio. Una versión mínima puede usar alimentación y velocidad.

8.6. Objetivo de control

Una formulación inicial es

$$\min_u \sum_k \left[-\lambda_Q Q_k + \lambda_E \frac{P_k}{Q_k} + \lambda_{80} (P_{80,k} - P_{80}^*)^2 + \lambda_{\Delta u} \|\Delta u_k\|^2 \right], \quad (49)$$

sujeta a límites de potencia, carga, velocidad, acciones y tasas de cambio. El desgaste se excluye del costo inicial salvo que exista un modelo validable.

8.7. Qué no promete esta primera formulación

Límite o cautela

La primera formulación no promete: simulación literal de todas las partículas de un SAG industrial; predicción completa de pulpa; rotura explícita de cada roca; control directo en planta; garantía de generalización mineralógica universal; ni un modelo validado de desgaste. Promete construir y evaluar un acoplamiento coherente entre microdinámica aprendida, conminución macroscópica y control predictivo en un entorno delimitado.

8.8. Criterios de éxito

Nivel	Criterio	Comparación
Microdinámica	rollout estable, error de posición/aceleración y contactos dentro de tolerancia	SLGNN frente a DEM y base-lines
Variables globales	potencia, torque, energía y espectros calibrados	heads aprendidas frente a cálculo DEM
Conminución	error de PSD y P_{80} en horizontes largos	PBM fijo, PBM-DEM y PBM-SLGNN
Cómputo	reducción sustancial del tiempo total de evaluación	campana DEM frente a sistema híbrido
Control	mejora de costo económico sin violaciones	regla/PID, MPC nominal y robusto
OOD	detección de escenarios fuera de soporte	pruebas de material, geometría y régimen no vistos

9. Prioridades para la próxima decisión del equipo

Para convertir el informe en un plan ejecutable, el equipo debería resolver primero cinco decisiones, sin intentar cerrar todas las elecciones futuras.

1. **Caso de referencia.** Elegir geometría, escala, material, régimen seco/húmedo y solver DEM.
2. **Variable puente.** Decidir si el primer coarse-graining se centrará en energía disipada, espectro de impacto, potencia o una combinación.
3. **Modelo macro inicial.** Seleccionar un PBM suficientemente simple para implementar y suficientemente físico para recibir el espectro.

4. **Objetivo de control inicial.** Elegir una sola prioridad principal, por ejemplo energía específica con restricción de throughput, o throughput con límite de potencia.
5. **Escenarios de generalización.** Definir desde el comienzo qué variaciones serán IID y cuáles OOD: velocidad, fill ratio, dureza, geometría, tamaño o composición.

La decisión sobre RL, desgaste avanzado o DEM-SPH no es prioritaria. Esas extensiones solo deben incorporarse cuando el prototipo básico demuestre que la interfaz SLGNN-modelo macro es informativa y estable.

10. Conclusiones

La propuesta se apoya en una cadena de ideas existentes, pero su combinación es una línea de investigación propia:

$$\underbrace{\text{GNS/SGN/SLGNN}}_{\text{microdinámica aprendida}} + \underbrace{\text{DEM-PBM/heterarquía}}_{\text{conminución multiescala}} + \underbrace{\text{estimación y gemelo}}_{\text{estado operacional}} + \underbrace{\text{MPC y RL supervisor}}_{\text{decisión restringida}}. \quad (50)$$

El aporte central no sería simplemente añadir más heads a una red. Sería construir una **interfaz físicamente significativa entre la dinámica granular aprendida y la dinámica macroscópica del proceso**, y demostrar que esa interfaz permite pronóstico y optimización a menor costo que el uso reiterado de DEM.

El esqueleto fundamental queda definido por siete compromisos: modularidad híbrida, SLGNN como núcleo, coarse-graining explícito, modelo macroscópico separado, estimación de estados, decisión restringida e incertidumbre con despliegue gradual. Las demás decisiones permanecen abiertas y deberán resolverse mediante evidencia, no por anticipación.

Síntesis

La recomendación final es comenzar con un prototipo de cuatro bloques: SLGNN multitarea, espectro energético, PBM informado por energía y MPC en simulación. Este núcleo es suficientemente concreto para orientar implementación y suficientemente flexible para incorporar más adelante estimación de planta, RL supervisor, desgaste, pulpa y circuito extendido.

Bibliografía

Referencias

- [1] Equipo de trabajo del proyecto SLGNN. *Estado del arte en simulaciones DEM y modelado multifísico en la dinámica de molinos SAG*. Documento interno aportado al proyecto, 2026.
- [2] A. Sanchez-Gonzalez, J. Godwin, T. Pfaff, R. Ying, J. Leskovec y P. W. Battaglia. Learning to simulate complex physics with graph networks. *Proceedings of the 37th International Conference on Machine Learning*, PMLR 119, pp. 8459–8468, 2020.
- [3] Y. Choi y K. Kumar. Graph Neural Network-based surrogate model for granular flows. *Computers and Geotechnics*, 166:106015, 2024. DOI: 10.1016/j.compgeo.2023.106015.
- [4] S. Li y M. Sakai. Advanced graph neural network-based surrogate model for granular flows in arbitrarily shaped domains. *Chemical Engineering Journal*, 500:157349, 2024. DOI: 10.1016/j.cej.2024.157349.
- [5] R. Bhattoo, S. Ranu y N. M. A. Krishnan. Learning the dynamics of particle-based systems with Lagrangian graph neural networks. arXiv:2209.01476, 2022.
- [6] S. Garrido Núñez, D. L. Schott y J. T. Padding. Accelerating granular dynamics simulations: A graph neural network surrogate for complex high-energy ball milling. *Powder Technology*, 468:121653, 2026. DOI: 10.1016/j.powtec.2025.121653.
- [7] N. S. Weerasekara, M. S. Powell, P. W. Cleary, L. M. Tavares, M. Evertsson, R. D. Morrison, J. Quist y R. M. de Carvalho. The contribution of DEM to the science of comminution. *Powder Technology*, 248, 2013.
- [8] R. M. de Carvalho y L. M. Tavares. A mechanistic model of SAG mills. *Proceedings of the XXVII International Mineral Processing Congress / Comminution 2014*, 2014.
- [9] Y. Zou, Q. Zheng y R. Yang. A hybrid DEM-FRM-PBM model for parameter calibration and extended grinding in ball mills. *Minerals Engineering*, 237:110047, 2026. DOI: 10.1016/j.mineng.2025.110047.
- [10] M. S. Bisht, F. Guillard, P. Shelley, B. Marks y I. Einav. Heterarchical comminution model for SAG mills. *Minerals Engineering*, 233:109563, 2025. DOI: 10.1016/j.mineng.2025.109563.
- [11] A. L. Hinde y colaboradores. The application of a simplified approach to modelling tumbling mills, stirred media mills and HPGRs. *Minerals Engineering*, 2009.
- [12] J. L. Salazar, L. Magne, G. Acuña y F. Cubillos. Dynamic modelling and simulation of semi-autogenous mills. *Minerals Engineering*, 22(1):70–77, 2009. DOI: 10.1016/j.mineng.2008.04.009.
- [13] P. W. Cleary y colaboradores. Prediction of slurry grinding due to media and coarse rock interactions in a 3D pilot SAG mill using a coupled DEM-SPH model. *Minerals Engineering*, 2020.
- [14] J. D. le Roux, L. E. Olivier, M. A. Naidoo, R. Padhi y I. K. Craig. Throughput and product quality control for a grinding mill circuit using non-linear MPC. *Journal of Process Control*, 42:35–50, 2016. DOI: 10.1016/j.jprocont.2016.04.007.

- [15] J. D. le Roux, A. Steinboeck, A. Kugi y I. K. Craig. An EKF observer to estimate semi-autogenous grinding mill hold-ups. *Journal of Process Control*, 51:27–41, 2017. DOI: 10.1016/j.jprocont.2016.12.006.
- [16] W. A. Gough. SAG mill optimization using model predictive control. ANDRITZ Automation technical paper, 2015.
- [17] P. Quintanilla, F. Fernández, C. Mancilla, M. Rojas, M. Estrada y D. Navia. Digital twin with automatic disturbance detection for an expert-controlled SAG mill. *Minerals Engineering*, 2025; versión preliminar arXiv:2407.06216.
- [18] F. Reyes, M. Hilden, M. Yahyaei y G. Forbes. Reinforcement learning control of a SAG mill grinding circuit: first impressions and implications for process control. *Proceedings of the XXX International Mineral Processing Congress*, 2020.
- [19] M. Zanon y S. Gros. Safe reinforcement learning using robust MPC. arXiv:1906.04005, 2019.